

标题：Information-theoretic metric learning

主要介绍了马氏距离的分类方法

马氏距离定义如下：

$$d_A(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T A (\mathbf{x}_i - \mathbf{x}_j).$$

当距离为欧氏距离时，其中的 A 为单位矩阵；很显然，马氏距离是欧氏距离的推广。度量学习的核心就在于计算 A 矩阵。

设 X 为输入向量，其格拉姆矩阵为： $K_0 = X^T X$ ，我们需要得到这么一个矩阵 K ，其满足：

$$\begin{aligned} \min \quad & D_{\text{Breg}}(K, K_0) \\ \text{subject to} \quad & K_{ii} + K_{jj} - 2K_{ij} \leq u \quad (i, j) \in S, \\ & K_{ii} + K_{jj} - 2K_{ij} \geq l \quad (i, j) \in D, \\ & K \succeq 0. \end{aligned}$$

其中最小化目标称为 bregman 散度，定义如下：

$$D_{\text{Breg}}(K, K_0) = \text{Tr}(K K_0^{-1}) - \log \det(K K_0^{-1}) - n.$$

Bregman 散度是可以解出来的，设为 W ，其格拉姆矩阵即为目标矩阵 A

详细的算法如下：

ALGORITHM 1: Algorithm for information-theoretic metric learning

ITMETRICLEARN(X, S, D, u, l)

Input: X : input $d \times n$ matrix, S : set of similar pairs, D : set of dissimilar pairs, u, l : distance thresholds

Output: W : output factor matrix, where $W^T W = A$

1. Set $W = I_d$ and $\lambda_{ij} = 0 \forall i, j$

2. Repeat until convergence:

- Pick a constraint $(i, j) \in S$ or $(i, j) \in D$
- Let v^T be row i of X minus row j of X
- Set the following variables:

1. $w = Wv$

2. if (similarity constraint)

$$\gamma = \min \left(\lambda_{ij}, \frac{1}{\|w\|_2^2} - \frac{1}{u} \right)$$

$$\beta = \gamma / (1 - \gamma \|w\|_2^2)$$

else if (dissimilarity constraint)

$$\gamma = \min \left(\lambda_{ij}, \frac{1}{l} - \frac{1}{\|w\|_2^2} \right)$$

$$\beta = -\gamma / (1 + \gamma \|w\|_2^2)$$

3. $\lambda_{ij} = \lambda_{ij} - \gamma$

- Compute the Cholesky factorization $LL^T = I + \beta ww^T$

- Set $W \leftarrow L^T W$

3. Return W